



ESCUELA POLITÉCNICA NACIONAL

Facultad de Ingeniería en Sistemas

Detección de fallos mecánicos por acústica

Said Josue Bravo González

Escuela Politécnica Nacional

Jhon Alexander Solorzano Mendoza

Escuela Politécnica Nacional

Deysi Abigail Guachamin Guanuña

Escuela Politécnica Nacional

Quito – Ecuador

6 de octubre de 2026

Tabla de Contenidos

1. Introducción	1
1.1. Descripción del Problema	1
1.2. Solución	1
2. Objetivos del Proyecto	2
2.1. Objetivo General	2
2.2. Objetivos Específicos	2
3. Stack Tecnológico Inicial	2
Referencias	3

1. Introducción

En los últimos años, el avance en técnicas de aprendizaje automático (Machine Learning) y aprendizaje profundo (Deep Learning) ha transformado el mantenimiento predictivo y el monitoreo de maquinaria industrial y automotriz. Históricamente, la detección de fallos mecánicos ha dependido de la inspección auditiva humana o de sistemas basados en umbrales fijos; sin embargo, estos enfoques presentan serias limitaciones de escalabilidad, alta subjetividad y una reducida capacidad para aislar patrones acústicos anómalos en entornos ruidosos. Ante este desafío, el procesamiento digital de señales de audio combinado con modelos de inteligencia artificial permite identificar firmas acústicas sutiles asociadas a desgaste o averías prematuras, habilitando diagnósticos automáticos, reproducibles y en tiempo real directamente desde dispositivos móviles.

1.1. Descripción del Problema

Las averías mecánicas representan una contingencia recurrente para los propietarios de vehículos; sin embargo, la complejidad técnica de los sistemas automotrices y la curva de aprendizaje que demandan impiden que el usuario promedio identifique el origen de una falla. En la actualidad, el sector carece de herramientas de diagnóstico acústico accesibles y estandarizadas que permitan inferir anomalías mecánicas con alta precisión a partir de señales de audio. Esta brecha diagnóstica genera dos problemáticas críticas: por un lado, intervenciones innecesarias o reemplazos erróneos de piezas que no resuelven la causa raíz; por otro, una asimetría de información que deja al propietario vulnerable a sobrecostos, cobros desproporcionados y prácticas comerciales desfavorables por falta de un respaldo técnico objetivo.

1.2. Solución

Para mitigar esta problemática, este proyecto propone el desarrollo de una aplicación móvil que integra procesamiento digital de señales y modelos de aprendizaje profundo (Deep Learning) para el diagnóstico no invasivo de fallas mecánicas. El sistema captura el audio emitido por el vehículo en tiempo real, aplica técnicas de filtrado y reducción de ruido ambiental, y transforma las señales en representaciones tiempo-frecuencia (espectrogramas de Mel). Estas representaciones alimentan una red neuronal convolucional (CNN) optimizada para inferencia en dispositivos de recursos limitados, capaz de clasificar patrones anómalos asociados a averías específicas —como holguras en correas, desgaste en rodamientos o descalibraciones en la combustión—. Con ello, se proporciona al usuario un reporte técnico comprensible, objetivo e inmediato con el porcentaje de certeza del diagnóstico, reduciendo la incertidumbre y orientando la toma de decisiones antes de acudir a un taller.

2. Objetivos del Proyecto

2.1. Objetivo General

Desarrollar un sistema móvil de diagnóstico mecánico no invasivo basado en modelos de aprendizaje profundo y procesamiento digital de señales acústicas, capaz de clasificar patrones anómalos en vehículos automotrices mediante inferencia local (edge computing) y sin requerir conexión a internet.

2.2. Objetivos Específicos

1. Adquisición y preprocesamiento de datos:

Recolectar y acondicionar un conjunto de datos de señales acústicas vehiculares, aplicando técnicas de filtrado de ruido ambiental y transformación tiempo-frecuencia (espectrogramas de Mel) para la extracción de características acústicas representativas.

2. Entrenamiento y optimización del modelo:

Diseñar, entrenar y validar una arquitectura de red neuronal convolucional (CNN) orientada a la clasificación de 5 fallos mecánicos críticos, alcanzando un desempeño mínimo del 75 % en métricas de evaluación ponderadas (como precisión y F1-Score).

3. Compresión e inferencia en el borde (Edge AI):

Optimizar y cuantizar el modelo entrenado mediante TensorFlow Lite para permitir una ejecución eficiente y de baja latencia en procesadores móviles, garantizando autonomía operativa offline.

4. Desarrollo de la aplicación móvil y validación:

Implementar una interfaz de usuario intuitiva que integre el motor de inferencia local con el hardware de captura de audio del dispositivo, validando su precisión y tiempo de respuesta en escenarios de prueba con motores reales.

3. Stack Tecnológico Inicial

Componente	Tecnología	Justificación Técnica
DSP y Audio	librosa, scipy, numpy	Filtrado de ruido y conversión de audio a espectrogramas de Mel.
Modelado IA	TensorFlow / Keras	Entrenamiento y ajuste de la arquitectura convolucional (CNN).
Optimización Edge	TensorFlow Lite (TFLite)	Cuantización del modelo (INT8/FP16) para inferencia <i>offline</i> .
Desarrollo Móvil	Flutter (Dart)	Interfaz de usuario multiplataforma y captura de audio del micrófono.
Inferencia Móvil	tflite_flutter	Carga y ejecución local del binario <code>.tflite</code> en el dispositivo.
Métricas y Análisis	scikit-learn, matplotlib	Evaluación cuantitativa (F1-Score, matriz de confusión) y visualización.

Referencias

Ragaie, Malak. 2023. *Car Diagnostics Dataset*. Kaggle. <https://www.kaggle.com/datasets/malakragaie/car-diagnostics-dataset>.